

project 2

L.EIC – IART

André Cotrim up202305592

Dinis Noronha up202306120

João Cova up202307756

- O Grupo Brisa é um dos maiores operadores de autoestradas em Portugal, responsável pela gestão da infraestrutura rodoviária, monitorização do tráfego e coordenação da resposta a emergências.
- Contacto: Pedro Ferreira, Gerente de Operações.

problem

- O Grupo Brisa precisa de alocar eficientemente veículos de resposta a emergências ao longo da rede de autoestradas para garantir uma intervenção rápida em caso de acidentes rodoviários.
- Cada acidente exige o envio de três veículos de emergência. Assim, prever com precisão o número esperado de acidentes diários é essencial para o planeamento operacional, a distribuição de veículos e a preparação dos serviços de emergência.
- Atualmente, muitas decisões baseiam-se em regras fixas e análise humana. O nosso sistema utiliza *machine learning* para identificar padrões complexos entre os diferentes fatores e os acidentes rodoviários.

available data

Dados temporais: hora, dia da semana, mês, feriado

Dados meteorológicos: precipitação (mm), visibilidade (km), temperatura (°C), velocidade do vento (km/h)

Tráfego: densidade do tráfego

Infraestruturas: número de faixas, iluminação, zona de obras

Objetivo: número de acidentes

solution overview

- A solução consiste no desenvolvimento de modelos *machine learning* (RandomForestRegressor, XGBoost e LigthGBM) capazes de prever o número diário de acidentes rodoviários nas autoestradas portuguesas, assim antecipando acidentes rodoviários e melhorar o planeamento da resposta a emergências.
- Também foi implementado uma WebApp para prever o número de acidentes através da seleção de *inputs*.

Highway Accident Predictor 🚗

Predict number of accidents and vehicles needed


Select model

RandomForestRegressor


Hour of the day



Day of the week (0=Mon, 6=Sun)



Month of the year



Public holiday

No

Precipitation (mm)



Visibility (km)



Temperature (°C)



Wind speed (km/h)



Predict

Prediction Results

Predicted Accidents

3

Estimated Vehicles Needed

9

Dataset Sample

	hour	weekday	month	holiday	precipitation_mm	visibility_km	temperature_c	wind_speed_kmh	traffic_density	num_lanes	illumination	work_zone	num_accidents
0	20	0	1	0	7.4	8.3	10.9	49.1	3	2	1	1	2
1	6	5	11	0	0	9.9	11.2	78.2	4	2	1	0	1
2	10	0	2	0	0	9.8	8.1	3.9	6	2	1	0	1
3	20	4	6	0	0	9.5	20.8	26	2	2	1	0	1
4	11	1	6	0	0	10.2	24.5	6.4	6	3	1	0	0

predictive model

- O problema é formulado como uma tarefa de aprendizagem supervisionada de regressão, onde o objetivo é estimar o número de acidentes com base em variáveis.
- O modelo aprende uma função: $f(X) \rightarrow y$
x: variáveis; y: número de acidentes;
- O objetivo é aprender padrões e a relações não lineares entre as variáveis de entrada e o número de saída.

empirical study: setup

- Os dados foram gerados artificialmente com LLMs.
- O dataset foi dividido em teste e treino.
- A otimização dos hiperparâmetros foi realizada previamente numa fase experimental separada através de GridSearch (notebook).
- Os modelos foram treinados e depois testados com MAE (Erro Absoluto Médio), MSE(Erro Quadrático Médio), RMSE(Raiz do Erro Quadrático Médio), R^2 (Coeficiente de Determinação).
- Os modelos com melhor desempenho foram selecionados de acordo com estas métricas.
- Após a seleção final, os modelos foram re-treinados utilizando a totalidade do dataset, de forma a maximizar o conhecimento adquirido antes da sua exportação para utilização na aplicação web.

empirical study: results

	Linear	Ridge	Poisson	RandomForest Regressor	XGBoost	LigthGBM	Negative Binomial
MAE	1.43	1.43	1.43	1.42->1.36	1.44->1.34	1.36->1.35	1.44
MSE	3.4	3.40	4.40	3.31->3.11	3.47->3.00	3.13->3.05	3.46
RMSE	1.84	1.84	1.84	1.82->1.76	1.86->1.73	1.77->1.75	1.86
R ²	0.226	0.226	0.226	0.246->0.293	0.210->0.317	0.288->0.305	0.212
Feature importance				visibility_km 0.197430 precipitation_mm 0.168891 traffic_density 0.150207	precipitation_mm 0.229647 traffic_density 0.151868 visibility_km 0.141182	wind_speed_kmh 0.178844 time_of_day 0.154308 temperature_c 0.148855	

Decision Makers: Gestores de operações de tráfego

Technical Team: Equipa de TI

End Users: Equipas de despacho de emergência

expected challenges during development and deployment

Aspetos técnicos:

- Os dados gerados podem não representar totalmente as condições do mundo real.
- As condições meteorológicas e de tráfego são dinâmicas e difíceis de modelar com precisão.
- Existem muitos mais fatores além dos apresentados que podem influenciar a ocorrência de acidentes rodoviários.
- Acidentes são eventos relativamente raros, o que pode levar a conjuntos de dados desbalanceados.
- As condições rodoviárias podem variar significativamente entre regiões e períodos de tempo. Garantir que o modelo generaliza bem para segmentos de auto estrada não vistos.

Aspetos organizacionais:

- *stakeholders* precisam de confiar na fiabilidade do modelo.
- Resistência à tomada de decisões baseada em IA e mudança.
- Podem requerer explicações para as previsões, mas modelos podem ser pouco interpretáveis
- O modelo precisará de ser continuamente atualizado e monitorizado

unavailable data

Exemplos:

- Dados de fluxo de tráfego e congestionamento em tempo real obtido por GPS.
- Registos detalhados de acidentes, incluindo localização, gravidade e tempo de resposta.
- Dados de comportamento do condutor, como padrões de velocidade e travagens.
- Dados do estado do condutor, como fadiga, distração ou consumo de álcool.
- Dados meteorológicos localizados de alta resolução (por exemplo, nevoeiro, gelo, microclimas).
- Condições da infraestrutura rodoviária e estado de manutenção.

Desafios envolvidos na recolha destes dados:

- Privacidade e proteção de dados
- Custo de infraestrutura
- Dados de terceiros
- Qualidade e consistência dos dados

- Previsões incorretas podem levar à insuficiência de recursos de emergência.
- Dados sintéticos ou incompletos podem não representar as condições do mundo real.
- Falta de transparência e interpretabilidade
- Privacidade e proteção de dados